

내용

[1 일차 오전] Cloud & AWS 소개 + AWS SageMaker Canvas 분류 모델	2
개요	2
기본 정보	2
학습목표	2
사전 준비사항	2
1. 실습 환경 설정	3
1.1 AWS 계정 로그인	3
2.2 SageMaker 도메인 생성	5
2. [강사시연] 샘플데이터를 사용한 Canvas 분류 실습 예제	10
2.1 데이터셋 및 모델 생성	10
3. [학생 주도 진행] TMDB 데이터를 사용한 Canvas 분류 실습	25
3.1 데이터셋 생성	25
3.2 예측 결과 분석	30
3.3 모델 테스트 (옵션)	31
3.4 데이터 탐색 (옵션)	32
4. Canvas 에서 인스턴스 중지	33
4.1 인스턴스 중지	33

[1 일차 오전] Cloud & AWS 소개 + AWS SageMaker Canvas 분류 모델

개요

기본 정보

- **세션명:** Cloud & AWS 소개 + Amazon SageMaker Canvas 를 활용한 분류 모델
- **소요시간:** 3 시간 (09:30 ~ 12:30)
- **대상:** 대학생 (AWS 초보자)
- **AWS 리전:** ap-northeast-2 (서울)
- **주 실습 데이터:** TMDB (The Movie Database) 데이터셋 - Kaggle 공개 데이터

학습목표

1. Cloud Computing 의 개념과 AWS 서비스 생태계 이해
2. AWS AI/ML 서비스군의 역할과 특징 파악
3. Machine Learning 기초 개념 습득
4. SageMaker 를 통한 ML 실습
5. TMDB 영화 흥행 성공 예측 모델 구축 및 분석

사전 준비사항

학생 준비 - [] AWS 계정 (강사 제공) - [] 웹 브라우저 (Chrome, Firefox, Safari 등)

1. 실습 환경 설정

1.1 AWS 계정 로그인

Step 1: AWS 콘솔 접속

1. 웹 브라우저 주소 표시줄에 `https://console.aws.amazon.com` 입력
2. AWS Management Console 로그인 페이지 표시
3. **Account ID, IAM user name, Password** 입력
4. “Sign in” 클릭

Step 2: 리전 확인 및 변경

1. 콘솔 우측 상단의 **리전 드롭다운** 클릭
2. 리전 목록에서 **Asia Pacific (Seoul) ap-northeast-2** 선택
3. 페이지 자동 새로고침

확인 방법 - 우측 상단에 “ap-northeast-2” 표시되는지 확인 - 리전 선택이 맞아야 실습 리소스가 올바른 위치에 생성됨

Step 3: OTP 설정

1. 콘솔 우측 상단의 **계정** 클릭 후 **보안 자격 증명**



2. MFA 할당멀티 팩터 인증(MFA) 등록

멀티 팩터 인증(MFA) (1)

삭제

재동기화

MFA 디바이스 할당

MFA를 사용하여 AWS 환경의 보안을 강화합니다. MFA로 로그인하려면 MFA 디바이스의 인증 코드가 필요합니다. 각 사용자는 MFA 디바이스를 최대 8개까
지 할당할 수 있습니다. [자세히 알아보기](#)

3. 디바이스 옵션 항목에서 “패스키 또는 보안 키” 선택 후 진행

(만일 개인 노트북이 아닌 학교 PC 일 경우 “인증 관리자 앱” 선택)

MFA device

디바이스 옵션

사용자 이름과 암호 외에도 이 디바이스를 사용하여 계정에 인증합니다.



패스키 또는 보안 키

지문, 얼굴 또는 화면 잠금을 사용하여 인증합니다. 이 디바이스에서 패스키를 생성하거나 FIDO2 보안 키와 같은 다른 디바이스를 사용하세요.

AWS recommends using a passkey or security key as an MFA device as they provide the most protection against attacks such as phishing.



인증 관리자 앱

모바일 디바이스 또는 컴퓨터에 설치된 앱에서 생성된 코드를 사용하여 인증합니다.



하드웨어 TOTP 토큰

하드웨어 TOTP 토큰 또는 기타 하드웨어 디바이스에서 생성된 코드를 사용하여 인증합니다.

4. [학교 PC 사용할 경우만: Google Authenticator 를 핸드폰에 설치 후 안내대로 등록

인증 관리자 앱

가상 MFA 디바이스는 QR 코드를 스캔하여 구성할 수 있는 디바이스에서 실행되는 애플리케이션입니다.

1

모바일 디바이스 또는 컴퓨터에 Google Authenticator, Duo Mobile 또는 Authy 앱과 같은 호환 애플리케이션을 설치합니다.

[호환되는 애플리케이션 목록 참조](#)

2

QR 코드 표시

인증 관리자 앱을 열고 이 페이지에서 **QR 코드 표시**를 선택한 다음, 앱을 사용하여 코드를 스캔합니다. 또는 보안 키를 입력할 수 있습니다. [보안 키 보기](#)

3

하단에 두 개의 연속된 MFA 코드를 입력합니다

하단에 가상 앱의 코드를 입력하세요

MFA 코드 1

30초간 기다린 후 두 번째 코드를 입력하세요.

MFA 코드 2

Cancel

Previous

MFA 추가

2.2 SageMaker 도메인 생성

목적: SageMaker Canvas 를 사용하기 위한 도메인 및 사용자 프로필 생성

사전 확인: 기본 실행 역할 (IAM Role)

상황: SageMaker 도메인을 생성하려면 IAM 실행 역할이 필요

Step 1: SageMaker 콘솔 접속

1. AWS 콘솔 메인 페이지에서 “Services” 클릭
2. 검색창에 Amazon SageMaker AI 입력
3. Amazon SageMaker AI 클릭(주의 : Amazon SageMaker 가 아닌 AI 가 붙어야 함)

경로: <https://ap-northeast-2.console.aws.amazon.com/sagemaker/home?region=ap-northeast-2#/dashboard>

Step 2: 도메인 생성 페이지 접속

1. 좌측 메뉴에서 “Admin configurations” 확장
2. “Domains” 클릭 후 도메인 생성 클릭



Step 3: 도메인 설정

1. “단일 사용자용 설정” 선택 후 클릭

SageMaker 콘솔은 Amazon SageMaker 도메인에서 SageMaker 도메인을 구성합니다.

단일 사용자용 설정(빠른 설정)

Amazon SageMaker가 계정을 구성하고 SageMaker 도메인에 대한 권한을 설정하도록 합니다.

- ✓ AmazonSageMakerFullAccess 정책을 사용하는 새로운 IAM 역할
- ✓ 보안 게이트웨이를 통한 퍼블릭 인터넷 액세스
- ✓ 표준 암호화를 통한 안전한 워크스페이스
- ✓ SageMaker MLflow
- ✓ 모든 SageMaker Studio 애플리케이션 및 IDE

단일 사용자 도메인과 SageMaker를 처음 시작하려는 사용자에게 적합합니다.

조직용 설정

권한, 통합 및 암호화를 포함해 계정 구성의 모든 측면을 제어합니다.

- ✓ 세분화된 권한 및 정책이 있는 사용자 지정 IAM 역할
- ✓ IAM 또는 IAM Identity Center 인증(AWS SSO 후속 인증)
- ✓ VPC 네트워킹 및 보안 그룹 구성
- ✓ 강화된 데이터 보호를 위한 사용자 지정 KMS 암호화 키
- ✓ 사용자 지정 SageMaker Studio 인터페이스
- ✓ SageMaker MLflow
- ✓ 프라이빗 및 공유 스페이스의 EBS 스토리지 옵션


사용자 그룹이 큰 관리자에게 더 적합하지만 지금 빠르게 설정하고 싶다면 나중에 언제든지 계정 구성 설정을 업데이트할 수 있습니다.

기타 도메인 설정 옵션

설정

Amazon SageMaker Studio

기계 학습 개발 환경을 설정하고 있습니다.



환경 설정 중...

개발을 시작하는 데 필요한 워크스페이스와 모든 리소스를 바로 구축하고 있습니다.

- ✓ AmazonSageMakerFullAccess 정책을 사용하는 새로운 IAM 역할
- ✓ 보안 게이트웨이를 통한 퍼블릭 인터넷 액세스
- ✓ 표준 암호화를 통한 안전한 워크스페이스
- ✓ 모든 SageMaker Studio 애플리케이션 및 IDE

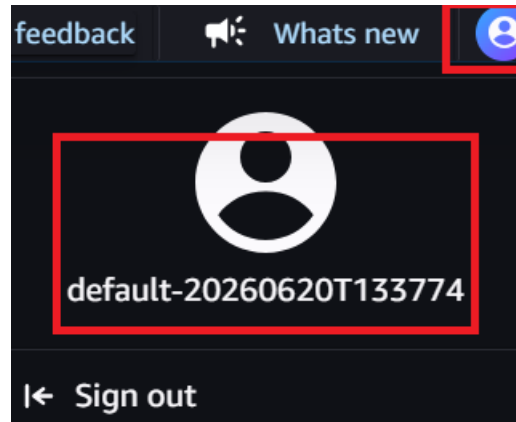
이 프로세스는 청구 비용이 발생하는 리소스를 생성합니다.

100%

동영상을 보고 계셨거나 브라우저가 팝업을 차단한 것으로 확인되었습니다.
준비가 되었으면 아래를 클릭하여 Studio를 여세요.

Studio 열기

[중요] 이후 스튜디오 열기 클릭 후 자신의 ID 기록




Step 4: tag 설정

1. 생성된 도메인 클릭



2. 하단의 “태크” 부분에서 편집 클릭 후 2 개의 태그 추가

- 첫번째 : 키: User(대문자로 시작), 값 : 본인의 AWS 아이디 (예 : awsclass005)
- 두 번째 : 키: Team(대문자로 시작), 값 : awsclass001 ~ awsclass040 학생은 A 입력, awsclass041 ~ awsclass080 학생은 B 입력



Step 5: IAM 권한 설정

1. 생성한 SageMaker 에서 AWS 리소스 호출을 위한 권한 설정

IAM 메뉴로 이동 : <https://us-east-1.console.aws.amazon.com/iam/home?region=ap-northeast-2#/home>

2. 액세스관리 -> 역할에서 자신이 생성한 AmazonSageMaker-ExecutionRole-{자신이 생성한 ID}을 찾아 클릭

The screenshot shows the AWS IAM console interface. On the left, the 'IAM' menu is highlighted, and the '역할' (Roles) option is selected. The main panel displays a list of roles under the heading '역할 (46) 정보'. The first role, 'AmazonSageMaker-ExecutionRole-20260610T152066', is highlighted with a red box. The table lists roles with their names and associated AWS services (all are 'sagemaker').

역할 이름	신뢰할 수 있는 개체
AmazonSageMaker-ExecutionRole-20260610T152066	AWS 서비스: sagemaker
AmazonSageMaker-ExecutionRole-20260610T192997	AWS 서비스: sagemaker
AmazonSageMaker-ExecutionRole-20260610T231373	AWS 서비스: sagemaker
AmazonSageMaker-ExecutionRole-20260616T144873	AWS 서비스: sagemaker
AmazonSageMaker-ExecutionRole-20260617T185262	AWS 서비스: sagemaker
AmazonSageMaker-ExecutionRole-20260617T193399	AWS 서비스: sagemaker
AmazonSageMaker-ExecutionRole-20260620T105785	AWS 서비스: sagemaker
AmazonSageMaker-ExecutionRole-20260620T133774	AWS 서비스: sagemaker

3. 권한 추가 버튼 클릭 해 아래의 권한 추가


AmazonS3FullAccess

AmazonBedrockFullAccess

AmazonRekognitionFullAccess

AmazonTextractFullAccess

ComprehendFullAccess



2. [강사시연] 샘플데이터를 사용한 Canvas 분류 실습 예제

2.1 데이터셋 및 모델 생성


Step 1: 샘플 데이터셋 준비

샘플 데이터셋 준비를 위해 파이썬을 사용해 데이터셋을 생성하는 코드 수행 준비 시작

Step 2: 데이터셋 생성

1. JupyterLab 생성

SageMaker Studio-> JupyterLab-> Create JupyterLab space > Run Space



Create JupyterLab space

Name

Enter a name (1-62 characters) using letters, numbers, and dashes only. 0/63

Sharing

☒ Private
The space and application will only be accessible by you

☐ Share with my domain
Allow all users in your domain to access and use the application.

Cancel Create space

SageMaker Studio > Jupyterlab > Teach Lab Chj

Applications (5)

- JupyterLab
- Canvas
- Code Edi...
- MLflow
- More Apps

teach-lab-chj Private

JupyterLab • 5 GB • ml.t3.medium

Run space Status Stopped Instance ml.t3.medium Image Sagemaker Distribution 4.1.3

생성 진행 시간 대기 후 완료되면 “Open JupyterLab” 클릭

SageMaker Studio > Jupyterlab > Teach Lab Chj

Applications (5)


- JupyterLab
- Canvas
- Code Edi...
- MLflow
- More Apps

teach-lab-chj Private

JupyterLab • 5 GB • ml.t3.medium


Stop space Open JupyterLab Status Running Instance ml.t3.medium Image Sagemaker Distribution 4.1.3

File -> New -> Notebook 클릭 후 Python3 선택



Select Kernel

Select kernel for: "Untitled.ipynb"



다음 코드를 사용해 데이터셋 생성

첫번째 데이터셋 : 가상의 데이터를 랜덤하게 생성하는 코드

```

import pandas as pd # 데이터프레임(표 형태의 데이터)을 다루기 위한 라이브러리
import numpy as np  # 수학적 계산 및 무작위 수(난수) 생성을 위한 라이브러리
import random       # 무작위 선택을 위한 파이썬 표준 라이브러리
import boto3        # AWS(아마존 웹 서비스) 연동용

# 1. 난수 생성을 위한 시드(Seed) 고정 (매번 실행할 때마다 똑같은 무작위 데이터가
# 생성되도록 함)
np.random.seed(42)
random.seed(42)

# 가상 데이터 생성에 사용할 장르와 영화 제목 목록
korean_genres = ['액션', '드라마', '코미디', '로맨스', '스릴러', '판타지', '공포',
                 '애니메이션', '가족', '다큐멘터리']
movie_titles = [
    '국가대표', '탐정', '괴물', '도둑들', '공조', '검사외전', '내 친구의 집은
    어디인가',
    '군함도', '암살', '베테랑', '터널', '골든슬럼버', '국가대표 2', '대호', '밀정',
    '특전사령부', '범죄도시', '마약왕', '신의 한수', '나쁜 녀석들', '스윗홈',
    '나이트비트 아웃',
    '악인전', '흑성탈출', '전쟁 영화', '한산', '명량', '적의', '공중도둑', '신세계',
    '연평해전', '타짜', '혜화역 1번 출구', '원더', '럭키', '캐스팅', '살인', '계획',
    '복수는 나의 것', '엄마는 외계인', '아저씨', '곡성', '살인자의 기억법', '라이언
    고슬링',
    '미션임파서블', '분노의 질주', '스타워즈', '어벤저스', '반도', '스파이더맨',
    '배트맨',
    '조커', '더 라이트하우스', '컨테이션', '블랙팬서', '캡틴마블', '어벤저스엔드게임'
]

# 2. 영화 데이터셋을 무작위로 만드는 함수 (기본값: 1000 개 영화)
def generate_movie_dataset(n_movies=1000):
    # 생성된 데이터들을 저장할 빈 딕셔너리(각 열이 될 리스트들)
    data = {
        'title': [], 'genre': [], 'budget': [], 'revenue': [],
        'director_popularity': [], 'cast_popularity': [], 'runtime': [],
        'release_month': [], 'vote_average': [], 'production_company_size': [],
        'marketing_score': [], 'sequel_flag': [], 'hit_10M': []
    }

    # 지정한 영화 개수(n_movies)만큼 반복하며 한 줄씩 데이터를 만듭니다.
    for i in range(n_movies):
        # [영화 제목 설정] 영화 제목 목록을 순환하며 중복될 경우 뒤에 ' 2', ' 3'
        # 번호를 붙임
        title_idx = i % len(movie_titles)
        if i >= len(movie_titles):

```

```

        title = f"{movie_titles[title_idx]} {i // len(movie_titles) + 1}"
    else:
        title = movie_titles[title_idx]

    # [장르 설정] 무작위로 하나의 장르 선택
    genre = random.choice(korean_genres)

    # [제작비(budget) 설정] 로그정규분포를 활용해 생성하고, 최소 10 억~최대 500 억
    # 사이로 제한 (소수점 첫째자리 반올림)
    budget = np.random.lognormal(mean=np.log(50), sigma=1.0)
    budget = round(max(10, min(500, budget)), 1)

    # [감독 및 배우 인지도 설정] 평균 50, 표준편차 25 인 정규분포로 생성 후 0~100
    # 사이로 제한
    director_popularity = round(max(0, min(100, np.random.normal(50, 25))), 1)
    cast_popularity = round(max(0, min(100, np.random.normal(50, 25))), 1)

    # [상영시간(runtime) 설정] 평균 115 분, 표준편차 20 분인 정규분포로 생성 후
    # 90~180 분 사이로 제한
    runtime = max(90, min(180, int(np.random.normal(115, 20))))

    # [개봉월(release_month) 설정] 1월부터 12 월 중 무작위 정수 하나 선택
    release_month = random.randint(1, 12)

    # [평점(vote_average) 설정] 평균 6.5, 표준편차 1.5 인 정규분포로 생성 후
    # 1~10 점 사이로 제한
    vote_average = round(max(1.0, min(10.0, np.random.normal(6.5, 1.5))), 1)

    # [제작사 규모 설정] 1(소형), 2(중형), 3(대형) 중 하나를 무작위 선택
    production_company_size = random.choice([1, 2, 3])

    # [마케팅 점수 설정] 0~100 점 사이로 제한된 인지도 점수 생성
    marketing_score = round(max(0, min(100, np.random.normal(50, 25))), 1)

    # [속편 여부(sequel_flag) 설정] 25% 확률로 속편(1), 아니면 (0)
    sequel_flag = 1 if random.random() < 0.25 else 0

    # [성공 공식 계산] 각 요소에 가중치를 곱해 기본 성공 점수 계산 (총합 1.0 만점)
    success_score = (
        (budget / 500) * 0.25 +          # 제작비 비중 25%
        (director_popularity / 100) * 0.25 +  # 감독 인지도 비중 25%
        (cast_popularity / 100) * 0.20 +      # 배우 인지도 비중 20%
        (vote_average / 10) * 0.15 +         # 평점 비중 15%
        (marketing_score / 100) * 0.15       # 마케팅 비중 15%
    )

```

```

    )

    # 성공 점수에 약간의 무작위 노이즈를 섞어서 최종 성공 확률(0.05 ~ 0.95
사이)을 만듭니다.
    success_probability = min(0.95, max(0.05, success_score +
np.random.normal(0, 0.1)))

    # 속편이거나, 성수기(7, 8, 12 월)에 개봉하면 성공 확률을 가산합니다.
    if sequel_flag == 1:
        success_probability = min(0.95, success_probability + 0.15)
    if release_month in [7, 8, 12]:
        success_probability = min(0.95, success_probability + 0.1)

    #최종 계산된 확률에 따라 천만 관객 돌파 여부(1 또는 0)를 결정합니다.
    hit_10M = 1 if random.random() < success_probability else 0

    # [관객수 및 매출액(revenue) 결정] 천만 돌파 여부에 따라 관객수를 무작위로
부여합니다.
    if hit_10M == 1:
        audience = np.random.normal(loc=15_000_000, scale=5_000_000)
        audience = max(10_000_000, audience) # 천만 돌파 영화는 무조건 1000 만
명 이상으로 고정
    else:
        audience = np.random.normal(loc=5_000_000, scale=2_000_000)
        audience = max(100_000, min(9_999_999, audience)) # 실패 영화는
10 만~999 만 명 사이

    # 매출액 계산: 대략 [관객수 * 12,000 원]을 계산한 후 백만 원
단위(1,000,000)로 변환해 소수점 첫째자리까지 저장
    revenue = round(audience * 12 / 1_000_000, 1)

    # 생성된 한 편의 영화 데이터를 처음에 만든 딕셔너리의 리스트들에 각각
추가(append)합니다.
    data['title'].append(title)
    data['genre'].append(genre)
    data['budget'].append(budget)
    data['revenue'].append(revenue)
    data['director_popularity'].append(director_popularity)
    data['cast_popularity'].append(cast_popularity)
    data['runtime'].append(runtime)
    data['release_month'].append(release_month)
    data['vote_average'].append(vote_average)
    data['production_company_size'].append(production_company_size)
    data['marketing_score'].append(marketing_score)

```

```

        data['sequel_flag'].append(sequel_flag)
        data['hit_10M'].append(hit_10M)

    # 완성된 딕셔너리 데이터를 판다스의 DataFrame(표) 구조로 만들어 반환합니다.
    return pd.DataFrame(data)

# 3. 이상치(Outlier) 전처리 함수
def preprocess_data(df):
    # 데이터프레임에서 숫자형(Numeric) 열들만 골라냅니다.
    numeric_columns = df.select_dtypes(include=[np.number]).columns

    # 각 숫자형 열들을 돌며 사분위수(IQR) 기준을 벗어나는 극단적인 값들을 한계값으로
    # 조절(Clip)합니다.
    for col in numeric_columns:
        q1 = df[col].quantile(0.25) # 하위 25% 지점의 값
        q3 = df[col].quantile(0.75) # 상위 75% 지점의 값
        iqr = q3 - q1 # 그 사이의 범위값(IQR)

        lower = q1 - 1.5 * iqr # 정상 범위의 하한선
        upper = q3 + 1.5 * iqr # 정상 범위의 상한선

        # 하한선보다 작으면 하한선 값으로, 상한선보다 크면 상한선 값으로 깎아냅니다.
        df[col] = df[col].clip(lower=lower, upper=upper)
    return df

# --- 메인 실행 흐름 ---

# 1) 1000 개의 가상 영화 데이터를 생성합니다.
df = generate_movie_dataset(1000)

# 2) 극단적인 수치 데이터를 다듬는 전처리를 수행합니다.
df = preprocess_data(df)

# 3) 'movie_box_office_prediction.csv' 파일로 저장합니다. (한글 깨짐 방지를 위해
utf-8-sig 사용)
file_name = "movie_box_office_prediction.csv"
df.to_csv(file_name, index=False, encoding="utf-8-sig")

# 4) 생성된 데이터의 상위 5 개 줄을 출력합니다.
print("--- 데이터 상위 5 개 행 보기 ---")
print(df.head())

# 5) 천만 영화(1)와 실패 영화(0)의 개수를 각각 카운트하여 출력합니다.
print("\n--- 천만 돌파 여부 빈도수 구하기 ---")

```




```
print(df["hit_10M"].value_counts().sort_index())

# 6) 전체 데이터 중 천만 영화가 차지하는 비중(평균)을 백분율(%)로 출력합니다.
print(f"\n 천만 관객 돌파율: {(df['hit_10M'] == 1).mean() * 100:.2f}%")
```

이후 생성된 파일을 다운로드


2. 완료 후 주피터랩 종료

러닝 상태인 주피터랩을 stop 버튼을 클릭해 종료




Step 3: 캔버스를 사용한 데이터셋 준비


1. SageMaker Studio -> Canvas 메뉴에서 Run Canvas 클릭




2. 생성 완료 후 Open Canvas 클릭




3. Canvas 에서 Dataset 메뉴로 이동



4. 첫번째 데이터셋 생성 : Import data 클릭 후 Tabular 선택





5. 데이터셋 이름 지정

Create a tabular dataset

×

Dataset name

test-dataset-01

Use only letters, numbers, spaces, dashes, colons, and underscores, up to 64 characters.

Cancel

Create

6. **Select a data source** 에서 local 선택 후 생성한 데이터셋 CSV 파일 선택

random_movie_box... : Create Tabular dataset ✕

Select a data source: Local upload

Upload files to import

Drag a CSV or Parquet file here

or


☁ Select files from your computer

[To create an LLM dataset](#)

Cancel Preview dataset

Step 4: 캔버스를 사용한 모델 실행 및 예측 1

1. SageMaker 에서 **My models** 메뉴 선택 후 **New model** 클릭



2. **model** 이름 지정

Create new model

Model name

Model name

Enter a model name. Use only letters, numbers, and underscores, up to 32 characters.

Problem type

Select the problem type you want the model to solve.

Predictive analysis

Build models using tabular datasets to predict single or multiple categories as well as regression and time-series forecast problems.

Image analysis

Build models using image datasets to predict single or multiple categories for image classification problems.

Text analysis

Build models using tabular datasets to predict single or multiple categories for text classification problems.

Fine-tune foundation model

Customize a foundation model on your data to improve its performance for a specific task or domain.

Cancel

Create

3. 생성한 첫번째 데이터셋 지정

My models > movie_box_office_classifier > Version 1

+ Create new version

↺

⋮

Select

Build

Analyze

Predict

Deploy

ⓘ

There's a new way to join data. You can now join datasets by creating a data flow in Data Wrangler. [Learn how to join data](#)

Import and prepare

×

Select dataset

You can import a tabular dataset or choose one that has already been imported. Your dataset must contain at least one input column and a target column.

	Name		Columns	Rows	Cells	Create
✓	lab01	V1	13	1,000	13,000	06/10/


4. 타겟 열을 hit_10M(관객 천만명) 으로 지정

5. 최종 포함 피쳐

- budget (제작 예산)
- runtime (영화 길이)
- vote_average (평점)
- release_month (개봉 월)
- release_year (개봉 연도)
- popularity (인기도)

권장 특성에서 다음 열은 제외

- title(영화 제목): 고유 문자열이라 일반화에 큰 도움이 적을 수 있음
- genre(장르): 나중에 실험용으로 포함 가능
- revenue(수익): 타겟과 직접적으로 연결되어 정보 누수 가능성이 큼



6. Quick Build 를 클릭해 시작

Training settings 페이지

옵션 A: Standard Build (권장, 시간 충분할 경우)

- 장점: 높은 정확도, 여러 알고리즘 비교
- 단점: 1~2 시간 소요

옵션 B: Quick Build (시간 부족할 경우)

- 장점: 빠른 완성 (2~5 분)
- 단점: 정확도가 상대적으로 낮을 수 있음 - 추천: 이론 설명 후 빠른 체험용

Model training mode	
o Standard Build	
• 권장 (정확도 높음, 약 1~2 시간 소요)	
• Canvas 가 여러 알고리즘 자동 테스트	
• 비용: 약 \$3~5	


○ Quick Build

- 빠른 프로토타입 (약 2~5 분 소요)
- 정확도 낮을 수 있음
- 비용: 약 \$0.50



Step 5: 모델 성능 평가 지표 확인

Advanced metrics 탭에서 결과 확인



성능 해석 : 이진 분류 모델의 성능이 전반적으로 낮은 편이라는 걸 알 수 있습니다.

랜덤하게 임의로 생성한 데이터이기 때문에, 성능이 낮게 나온 것입니다.

- **Accuracy 56.5%:** 전체 예측 중 약 56.5%만 맞췄다는 뜻입니다. 즉, 10 개 중 4 개 이상은 틀리고 있어 전반적인 분류 정확도가 높지 않습니다.
- **F1 0.530:** 정밀도(Precision)와 재현율(Recall)의 균형을 보여주는 지표인데, 0.53 이면 두 성능이 모두 중간 이하 수준입니다. 모델이 양성과 음성을 균형 있게 잘 구분하지 못하고 있습니다.
- **Precision (모델이 Positive 라고 예측한 것 중, 실제로 Positive 인 비율) 56.322%:** 모델이 “Hit_10M = 1”이라고 예측한 것 중 실제로 맞은 비율이 56.322%라는 뜻입니다. 즉, 양성이라고 찍은 예측의 약 44%는 틀렸습니다.
- **Recall 50%:** 실제로 Hit_10M = 1 인 영화 중 절반만 잡아냈다는 뜻입니다. 다시 말해, 실제 성공 영화의 절반은 놓치고 있습니다.
- **AUC-ROC 0.53:** 분류 능력을 종합적으로 보는 지표인데, 0.5 가 무작위 수준이므로 0.53 은 거의 무작위에 가까운 성능입니다. 클래스 구분력이 매우 약하다는 신호입니다. 보통 수준이라면 최소 0.7 이상입니다.

해석의 의미

이 결과는 모델이 **성공 영화와 비성공 영화를 뚜렷하게 구분하지 못한다**는 뜻입니다.

특히 재현율이 50%라는 점은, 실제 성공작을 절반밖에 못 찾아내므로 “성공작을 놓치지 않는 것”이 중요한 상황에서는 부족합니다.

정밀도도 56%대라서, 성공이라고 예측한 영화도 거의 절반은 틀려서 예측 신뢰도가 낮습니다.

3. [학생 주도 진행] TMDb 데이터를 사용한 Canvas 분류 실습

3.1 데이터셋 생성

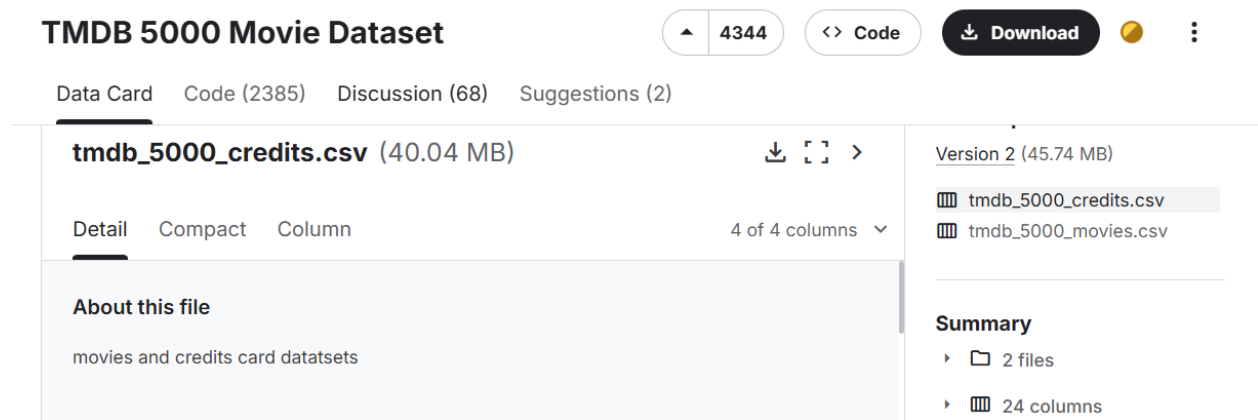
Step 1: 데이터셋 자료 준비

데이터 출처: Kaggle - TMDb 5000 Movies Dataset

<https://www.kaggle.com/datasets/tmdb/tmdb-movie-metadata>

필요 파일 다운로드 (회원 가입 필요)

- tmdb_5000_credits.csv
- tmdb_5000_movies.csv



TMDb 5000 Movie Dataset 4344 <> Code Download


Data Card Code (2385) Discussion (68) Suggestions (2)

tmdb_5000_credits.csv (40.04 MB)	tmdb_5000_movies.csv (45.74 MB)
Detail Compact Column	Summary
About this file	2 files
movies and credits card datasets	24 columns

Step 2: 데이터셋 생성

1. 테스트용 데이터셋 생성

업로드 버튼으로 TMDb 데이터 2 개 업로드



업로드 완료 확인

File Edit View Run Kernel Git Tabs Settings Help default-

Launcher x tmdb_5000_movies.csv x tmdb_5000_credits.csv x

Delimiter: ,

	movie_id	title	cast	crew
1	19995	Avatar	ene Renee", "order": 82}}	"name": "Min Windle"]}
2	285	aribbean: At World's End	Massoud", "order": 33}}	"name": "Katie Greathouse"]}
3	206647	Spectre	ovi\u0107", "order": 82}}	"name": "Hanz Kawson"]}
4	49026	The Dark Knight Rises	Newman", "order": 158}}	"Dileep Singh Rathore"]}
5	49529	John Carter	Billingere", "order": 26}}	"name": "Karin Silvestri"]}
6	559	Spider-Man 3	Wineteer", "order": 142}}	"name": "Greg Outcalt"]}
7	38757	Tangled	n Mertens", "order": 12}}	"name": "Mark Mitchell"]}
8	99861	Avengers: Age of Ultron	Nestwood", "order": 71}}	"": "Jamie Christopher"]}
9	767	nd the Half-Blood Prince	Gallacher", "order": 48}}	"name": "Stuart Wilson"]}
10	209112	erman: Dawn of Justice	elo Bem", "order": 151}}	"name": "Jason Fields"]}
11	1452	Superman Returns	ina Beatty", "order": 18}}	"e": "Guy Hendrix Dias"]}
12	10764	Quantum of Solace	an O'Hea", "order": 32}}	"e": "Michael G. Wilson"]}
13	58	ibbean: Dead Man's Chest	er S. Capp", "order": 32}}	"Cedric Nicolas-Troyan"]}
14	57201	The Lone Ranger	an Koenig", "order": 59}}	"", "name": "Lee Orloff"]}
15	49521	Man of Steel	"": "Raj Lal", "order": 32}}	"me": "Carlos Castillon"]}
16	2454	of Narnia: Prince Caspian	sov\u00e1", "order": 20}}	"ne": "Manning Tillman"]}
17	24428	The Avengers	a Grimm", "order": 114}}	"ame": "Mike Marcuzzi"]}
18	1865	ibbean: On Stranger Tides	ied Peters", "order": 34}}	"", "name": "Lee Orloff"]}
19	41154	Men in Black 3	an Bittner", "order": 17}}	"": "Mark Aaron Wagner"]}

TMDB 에서 다운로드 받은 파일 2 개를, 앞서 생성한 첫번째 데이터셋과 같은 형식으로 병합하는 코드를 작성해 만들어 봅니다.

강사에게 제공받은 “tmdb-dataset.ipynb” 노트북 파일을 사용해 실습합니다.

The screenshot shows a Jupyter Notebook environment. The left sidebar displays a file explorer for the directory `/SMU / sage /`. It lists several files: `movie_box_office_prediction...` (31s ago), `tmdb_5000_credits.csv` (49s ago), `tmdb_5000_movies.csv` (1m ago), `tmdb-dataset01-instructor.ipynb` (30s ago), and `tmdb-dataset01-student.ipynb` (2m ago). The main notebook area has a title bar with tabs for `0-overview-setup.ipynb`, `1-text-detection-exerc`, `2-forms-tables-exercis`, and `tmdb-dataset01-stude`. The active cell contains the following content:

TMDB 영화 데이터셋 전처리 실습

학습 목표

1. 두 개의 CSV 파일을 병합하여 하나의 통합 데이터프레임을 만듭니다.
2. 문자열로 저장된 JSON 컬럼을 파이썬 리스트/딕셔너리로 변환합니다.
3. 파생 변수(장르, 감독, 배우, 인지도 점수)를 직접 계산합니다.
4. 결측값/이상값을 처리하고 최종 데이터셋을 CSV로 저장합니다.

데이터 구조

```
tmdb_5000_movies.csv } title 기준 병합 → df (통합 데이터프레임)
tmdb_5000_credits.csv }
```

전처리 파이프라인


```
[1] 데이터 로드 & 병합
    ↓
[2] 보조 함수 정의 (JSON 파싱, 이름 추출, 감독 추출)
    ↓
```

참고 : 데이터셋 비교


구분	랜덤 데이터셋	TMDB 데이터셋
데이터 출처	난수로 생성	TMDB 실제 영화 데이터
목적	연습용 데이터 생성	실제 데이터 전처리
budget	랜덤 생성	TMDB budget 사용
revenue	랜덤 생성	TMDB revenue 사용
감독 인기도	랜덤	감독별 popularity 평균
배우 인기도	랜덤	배우 popularity 평균
marketing_score	랜덤	popularity+vote_count+budget 조합
sequel_flag	25% 확률	제목 패턴 분석
hit_10M	확률 계산	revenue 기준 생성

Step3: 캔버스를 사용한 모델 생성 및 예측 (어떤 요소가 흥행에 영향을 주는가?)

1. SageMaker 에서 **My models** 메뉴 선택 후 **New model** 클릭



2. **model** 이름 지정



3. 생성한 두번째 데이터셋(TMDB) 지정

Select

Build

Analyze

Predict

Deploy



There's a new way to join data. You can now join datasets by creating a data flow in Data Wrangler. [Learn how to join data](#)

[Import and prepare](#)


Select dataset

You can import a tabular dataset or choose one that has already been imported. Your dataset must contain at least one input column and a target column.

	Name		Columns	Rows	Cells	Create
☒	lab01	V1	13	1,000	13,000	06/10/


4. 타겟 열을 hit_10M(관객 천만명) 으로 지정

5. 권장 특성에서 다음 열은 제외

- title(영화 제목): 고유 문자열이라 일반화에 큰 도움이 적을 수 있음

- revenue(수익): 타겟과 직접적으로 연결되어 정보 누수 가능성이 큼

6. **Quick Build** 를 클릭해 시작



3.2 예측 결과 분석

Step 1: 모델 학습 완료 확인

학습 진행 상황 페이지에서 결과 확인 후 분석

Step 3: 두번째 모델 성능 평가 지표 확인

Advanced metrics 탭에서 결과 확인

Select

Build

Analyze

Predict

Deploy

Model status

Quick build

Accuracy

F1

Optimization metric

84.699%

0.780

The model predicts the correct Hit_10M 84.699% of the time.

Predict

Standard build

Deploy

Overview

Scoring

Advanced metrics

Model leaderboard

Positive Class

F1

Optimization metric

Accuracy

Precision

Recall

AUC-ROC

1

0

77.951%

84.699%

78.125%

77.778%

0.91

성능 해석 : 이 TMDb 데이터셋 결과는 **앞선 랜덤 데이터보다 훨씬 좋고, 실제로 쓸 만한 수준의 분류 성능**을 보여줍니다. 전반적으로 균형이 좋고, 클래스 구분력도 강합니다.

- **Accuracy 84.699%:** 전체 영화 중 약 84.7%를 맞췄다는 뜻입니다. 랜덤에 가까운 수준이 아니라, 상당히 안정적으로 분류하고 있습니다.
- **F1 0.780:** Precision 과 Recall 의 균형이 좋다는 의미입니다. 한쪽으로 치우치지 않고 성공/실패를 비교적 고르게 잡아내고 있습니다.
- **Precision 78.125%:** 모델이 “Hit_10M = 1”이라고 예측한 영화 중 약 78.1%가 실제로 맞았다는 뜻입니다. 즉, 성공이라고 찍은 예측의 신뢰도가 꽤 높습니다.
- **Recall 77.778%:** 실제로 Hit_10M = 1 인 영화 중 약 77.8%를 찾아냈다는 뜻입니다. 성공작을 놓치는 비율도 크지 않습니다.
- **AUC-ROC 0.91:** 클래스 구분력이 매우 좋다는 뜻입니다. 0.5 가 무작위 수준인데, 0.91 이면 성공과 비성공을 꽤 잘 구별하는 강한 모델입니다.

해석의 의미

이 결과는 모델이 단순히 데이터 패턴을 흉내 내는 수준을 넘어, 실제 구분력을 가진 예측 모델에 가깝다는 뜻입니다.

특히 Precision 과 Recall 이 모두 70% 후반대라서, 성공 예측을 꽤 믿을 수 있고 동시에 성공작도 많이 잡아냅니다.

AUC-ROC 0.91 은 모델의 분류 성능이 전반적으로 매우 좋다는 신호입니다.

3.3 모델 테스트 (옵션)

Step 1: 예측(Predict) 수행

Predict 탭에서 single prediction 선택 후 임의의 값을 넣은 후 update prediction 클릭

Predict target values

Batch prediction Single prediction

Modify values to predict hit_10M in real time.

Filter columns

Column	Value
title	The Host
genre	Drama
budget	2000000


hit_10M Prediction

You made 1 change to the values. Update for a new prediction and feature importance metrics.

Update prediction

Update prediction with feature importance

이후 결과 확인



3.4 데이터 탐색 (옵션)

Step 1: 데이터셋 확인

대출 승인 여부를 예측하는 분류 모델을 생성하려 한다.

canvas-sample-loans-part-1.csv 에서 **타겟(Target) 변수**와 **예측 변수(Features/대상을 선택할 컬럼)**를 어떻게 지정하면 좋을지 확인한다.

Home

Amazon Q

Data Wrangler

Datasets

My Models

Help

Log out

Datasets > canvas-sample-loans-part-1.csv V1 + Create a data flow Update dataset + Create a model

This dataset contains complete loan data for all loans issued from 2007-2011, including the current loan status and latest payment information. You can use this dataset to predict whether your customer will repay their loan. To learn more about how to build a model with this dataset, check our [workshop page](#). This dataset was obtained from [Kaggle](#).

Data Version history Auto update Dataset detail

Previewing up to the first 100 rows of canvas-sample-loans-part-1.csv

id	loan_status	loan_amount	funded_amount...	loan_term	interest_rate
1077501	fully paid	5000	4975	36	10.65
1077430	charged off	2500	2500	60	15.27

Dataset type: Tabular Total dataset cells (columns x rows): 19000 (19 x 1000) Data source: S3

4. Canvas 에서 인스턴스 중지


4.1 인스턴스 중지

✗ 나쁜 습관:

1. 학습 완료 후 instance 그냥 놔두기
 2. 컴퓨터 종료 안 함
- 추가 비용 계속 청구!

Step 1: 컴퓨팅 중지

Running instances 메뉴에서 구동중인 instance Stop



The screenshot shows the SageMaker Studio interface. On the left sidebar, under the 'Compute' section, 'Running instances' is highlighted. The main panel is titled 'Running instances' and contains a table of running instances. The table has columns: Name, Application, Status, Sharing, Instance, Storage, CreateBy, CreatedTime, and Action. Two instances are listed: 'test' (JupyterLab) and 'default-202606...' (Canvas). Both are in 'Running' status. The 'Action' column for each instance has a 'Stop' button highlighted with a red box.

Name	Application	Status	Sharing	Instance	Storage	CreateBy	CreatedTime	Action
test	JupyterLab	Running	Private	ml.t3.medium	5 GB	default-202606...	1 minutes ago	Stop
default-202606...	Canvas	Running	Private	system	-	default-202606...	1 hours ago	Stop